

数学 RAG 智能问答系统

测试报告（模块二：测试对象含 AI）

日 期	版 本	说 明	作 者
2026-09-22	1.0	整理真实运行与缺陷复现记录	AI 辅 助 整 理；小组姓 名待填写
2026-09-22	1.1	补充修复后 45 条回归与 S03 补测	AI 辅 助 整 理；小组姓 名待填写

目 录

1 被测对象及 AI 融合方案概述	3
2 AI 实践过程与成果	3
2.1 实践过程	3
2.2 新增测试成果	4
2.3 测试环境	4
3 AI 反思与批判	5
AI 辅助测试的反思（补充）	5
4 小组成员贡献度	6

1 被测对象及 AI 融合方案概述

被测对象为本地数学 RAG 问答系统。架构：用户问题→ChromaDB 向量召回 Top50→BGE 相关性重排 Top5→提示词组织→Qwen 生成→JSON 封装。生成模型 Qwen2.5-0.5B-Instruct；重排模型 bge-reranker-base；默认嵌入 all-MiniLM-L6-v2 ONNX；本地 Math_ShuZhi 知识库 2,215 条记录；召回 Top50，重排 Top5。

重点模块：RAG/RAG.py（132 行，rag、输入规范化、错误脱敏及角色覆盖防护）；Model/newChat.py（265 行，模型加载、消息构建、生成及输出封装）；prompt/prompt.py（19 行，参考数据与当前问题组织）。行数含空行和注释，按当前文件统计。app.py 前端不在本次验收范围。

选择方案 1（测试对象含 AI）。核心被测行为由模型推理和检索共同决定，不适合只用固定输入输出字符串比较；需要契约、边界、对比、稳定性及对抗测试结合。

输入：query、history、collection_name 及真实模型组件；输出：(entire_json, response, relative_knowledge_rerank)。正常分支为 chat.completion JSON；异常分支为脱敏 error JSON，非法集合名在入口抛 ValueError。测试难点包括生成随机性、缺少完整语义判定标准、检索指标与实际答案质量之间的差距。

同时使用 Codex 辅助环境排障、缺陷定位、修改和文档整理；这属于辅助方式，不改变方案 1 选型。未记录精确工具模型版本，不据此编造版本或成员贡献。

2 AI 实践过程与成果

2.1 实践过程

测试设计覆盖鲁棒性 R01~R16、公平性 F01~F08、安全性 S01~S12；修复后新增规则回归 G01~G09。前 36 条使用真实模型、检索或重排组件，后 9 条直接调用真实应用层规则函数，无 mock。F01~F06 使用 L1 召回非空/等量和部分 L2 Top50 Jaccard 阈值；F02 只验证 L1。

执行阶段：①按 README 准备 Python3.10、CUDA 模型环境；修正编码、依赖和批处理换行问题。②RAG.py 成功召回 5 条知识并生成 JSON。③初次 36/36 通过。④用户后续运行 S02 失败；缓存仅定位用例，未保存该次完整回答，不能虚构该次确切触发短语。⑤固定种子 0~7 诊断发现 4/8 回答声称解除限制，而原断言均未命中。⑥增加应用层拒绝保护、关闭相关原始流式输出、明确 system 边界、改为贪心解码、加强 S02 并新增 9 条回归。⑦全量 45/45 通过，再以更新后的提示词标记单独补测 S03 通过。

传统程序测试侧重类型、异常和精确返回值；AI 测试还需检查语义行为、输入变体与抽样稳定性。8 种子只是诊断样本，不可将 4/8 解释为总体攻击成功率。两次整轮耗时受提示词、生成长度、采样设置和缓存等共同影响，不作为严格性能优化对照。下表为真实日志摘要，不是终端截图。

阶段 / 证据	实际结果	解释
初次全量：tests.log/xml	36 passed ; 87 warnings ; 418.84s	一次通过未发现所有风险
诊断：s02_samples.json	8 个固定种子；4 个回答声称解除	观察到真实风险及漏检，非总体

阶段 / 证据	实际结果	解释
	限制；旧 markers 全部为空	统计
定向回归：s02_after.log	10 passed; 5.61s	S02+9 个规则参数
修 复 后 全 量： tests_after_s02.log/xml	45 passed; 0 失败/错误/跳过; 87 warnings; 130.49s	2026-09-22 16:25 起执行
更新标记补测：s03_after.log	1 passed; 2 warnings; 5.22s	不重复计入 45 条总数

2.2 新增测试成果

附录 1 提供全部 45 条用例的预置条件、输入、操作、预期、实际与追踪信息，满足至少 15 条 AI 相关用例要求。原 36 条与新增 9 条分别列示，参数化的每个输入计 1 条。下面列出覆盖与结果。

维度	用例	通过数	关键边界
鲁棒性	R01~R16	16/16	多数用例只保证契约； 不代表答案正确
公平性	F01~F08	8/8	F02 只检验服务规模对 等
安全性	S01~S12	12/12	已知载荷与指定输出断 言
应用层回归	G01~G09	9/9	5 个拒绝样本+4 个正常 反例

新增成果：5 条中英文角色覆盖命令拒绝+4 条正常数学/概念提问放行。S02 由弱契约改为成功契约，要求明确拒绝并检查解除限制/进入角色变体；去除仅因提到“Do Anything Now”即认定越狱的简单判断。S03 检测标记同步到新 system 提示词。正式记录 2 个缺陷：D001 角色覆盖防护不足、D002 安全测试判定漏检，均已在指定范围验证修复。环境兼容问题另作过程记录，不混入产品缺陷数量。

2.3 测试环境

Windows 11 家庭版中文版 10.0.26200; Intel Core Ultra 7 251HX; 物理内存约 15.43 GiB; NVIDIA GeForce RTX 5070 Laptop GPU, 显存 12231 MiB, 驱动 610.88. Python 3.10.21、PyTorch 2.7.1+cu128、Transformers 4.46.3、FlagEmbedding 1.3.4、ChromaDB 0.6.3、pytest 9.1.1; 项目.venv 复用 pamt 基础环境。

生成模型 Qwen2.5-0.5B-Instruct; 重排模型 bge-reranker-base; 默认嵌入 all-MiniLM-L6-v2 ONNX; 本地 Math_ShuZhi 知识库 2,215 条记录; 召回 Top50, 重排 Top5。

运行路径: D:\Googledownload\test2-main\test2-main。依赖补充: peft 0.13.2、datasets 3.1.0、pyarrow 19.0.1、sentence-transformers 3.3.1、posthog 3.25.0。模型权重通过 SHA256 校验。首次安装/下载需联网; 本轮主链路无需外部服务账户, 不在文档中抄录.env 或任何密码/API Key。

测试环境与系统相同。PowerShell 进入项目根目录, 执行 .\run_tests.bat --no-pause。脚本优先使用.venv, 启用 UTF-8 并保留退出码。定向验证: .\venv\Scripts\python.exe -m pytest tests/test_security.py::test_s02_roleplay_jailbreak tests/test_role_guard.py -v。

所有相对路径均相对于项目根目录。主要证据: run_logs/tests_after_s02.log、

tests_after_s02.xml、s02_samples.json、s02_after.log、s03_after.log；初次记录为 tests.log、tests.xml、rag.log。

3 AI 反思与批判

本节以系统本身的质量为主，并记录 AI 辅助测试的边界。结论基于留存证据，不把工具生成的文字当作事实。

- 做对的部分：默认“二次方程”示例完成 Top50 召回、Top5 重排、中文生成与 JSON 封装；R01 验证回答含方程主题且 token 统计正确；非法集合名、超长输入和异常脱敏通过各自断言。修复后的 S02 输出由应用层强制限定为拒绝文本。
- 做错的部分：修复前固定种子 0、2、3、5 出现“已经解除数学助手的所有限制”；说明小模型不可靠地遵循角色边界。另在 seed=4 诊断回答中出现对 $x^2+3x+2=0$ 的错误推导并给出 $x=-3$ （代入不为 0；正确根为 -1、-2）。此为附带质量观察，尚无独立数学正确性回归，也未宣称修复。不能仅凭现有证据归因于过拟合或训练数据偏差。
- 挑战：输出非唯一、随机采样导致重复运行差异；测试词面规则可能误报或漏报；弱契约允许受控错误，PASS 不等于正常回答；Top50 候选一致也不证明语义公平。F04 同时变化城市与商场/商店表述，隔离地域影响不充分；F02 未要求跨语言语义召回一致。
- 能否证明正确：不能。45/45 只说明当前环境、样本与断言范围内通过，可作为本地教学演示的回归依据，不能据此认定生产安全或完整数学正确性。角色覆盖规则只识别已知明确命令，可能漏掉变体或误拦引用攻击的讨论；且推理仍执行，不是算力消耗防护。应继续增加多种子对抗样本、数学标准答案/人工评审、多语言检索和并发性能评估。

现存事项：87 条 ChromaDB/Pydantic 弃用警告尚未消除；生成响应的 model 元数据默认仍写 Qwen2.5-1.5B-Instruct，与实际 0.5B 加载路径不符，当前测试未覆盖该字段。此为代码审查观察，待单独处理。

AI 辅助测试的反思（补充）

- 工具完成环境定位、真实组件执行、固定种子诊断、补丁及文档追踪；有效贡献应以源码和可复查日志为准。
- 最初 36 条全通过掩盖了安全漏洞；多次仅加提示词仍无法确保拒绝。若只追求绿色测试，可能错误地放宽断言或把确定性解码当成安全保证。
- 已实施改进是应用层拒绝、防止原始流式输出、改进测试判定和新增反例。当前记录没有成员个人操作轨迹，因此这些修改标为 AI 辅助完成、待成员确认，不虚构“人工修改”工作量。
- AI 定位为辅助者。它能快速执行与归纳，但需求边界、缺陷严重性、测试充分性和最终签字需要项目成员复核。

4 小组成员贡献度

未提供小组名单、分工和工时，不能据聊天内容推算个人贡献比例。下表留待成员据实际补齐；正式提交前各成员比例应合计 100%。本次 AI 辅助修改不自动归入任何成员。

成员 / 学号	实际分工	代码行数 / 发现缺陷	贡献比例
待填写	环境、用例、执行、修复、 文档分工待确认	待核实	待填写
其他成员按实际增补	待填写	待核实	待填写
合计	正式提交前核对	不将文件总行数等同个人 新增代码	待核对为 100%